LABORATUVAR 7 · ROBOWAAM ADVANCED · Tel Ark Eklemeli İmalat

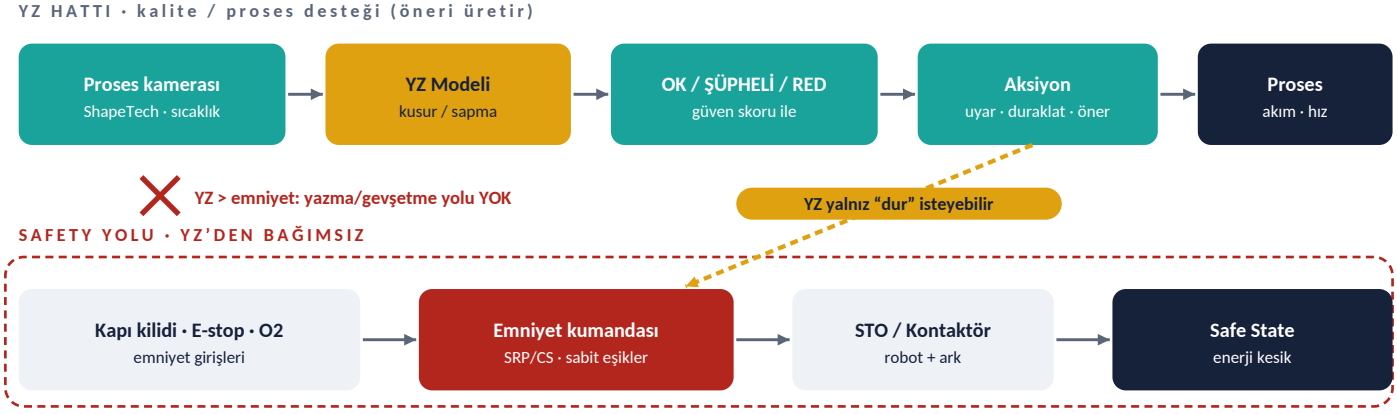
7 AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad **Muhammet Baykara** | Grup **Gece 4/B** | Tarih **24/10/2026**

> **Kavram — Prediction ≠ Safety:** Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: RoboWAAM'a YZ destekli proses/kusur denetimi (proses kamerası + ShapeTech + sensör verisi → kusur/sapma tespiti ve parametre önerisi) eklenmesi planlanıyor — proje aşaması değerlendirmesi yapıyorsunuz.



Prediction != Safety: güvenliği garanti eden mimari YZ'nin dışında tanımlıdır.

Görev — üç başarısızlıkta güvenli davranış

1 Model yanlış sınıflandırdı: Kusurlu katmana/parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Evet — "OK" yalnız bir öneridir, karar değildir. Yanlış negatif (kusuru kaçırma) kabul edilebilir bir tek-nokta olmamalıdır:

- **Bağımsız ikinci kontrol (kural tabanlı SPC):** voltaj, akım, tel hızı, hareket hızı, interpass sıcaklığı ve ShapeTech katman yüksekliği için deterministik limitler; YZ "OK" dese de limit aşılırsa durur/uyarır [S] (WAAMCtrl bu değişkenleri izliyor).
- **İnsan onayı:** kritik/emniyet-ilgili parçalarda (havacılık, basınçlı kap) YZ "OK"u operatör + kalite mühendisi onayı olmadan kalite kapısını geçirmez (human-in-the-loop).
- **Süreç sonrası doğrulama:** NDT (CT/ultrason/radyografi) ve kupon testi; YZ metriği "NDT ile uyumlu mu" diye izlenir (monitoring).
- **Emniyet etkisi:** yanlış sınıflandırma insana doğrudan zarar vermez (emniyet zinciri ayrı); ama parça emniyeti için kalite kapısı şarttır. Yanlış negatif oranı validasyonda ölçülür ve kabul eşiği tanımlıdır [V].

2 Girdi manipüle edildi: Kamera/sensör verisi bozuk veya sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Manipülasyon kaynağı kasıtsız (ark parlaması, duman, kirli lens) ya da kasıtlı olabilir (adversarial girdi, sensör akışına siber müdahale — Lab 3 S2 ile aynı sınıf). **Fark etme:**

- **Sensör sağlığı:** kare dondu mu, zaman damgası/sıra numarası tutarlı mı, aşırı "mükemmel" veya sabit veri; kendi kendine test.
- **Çapraz doğrulama:** görüntü ↔ elektriksel proses (akım/voltaj) ↔ ShapeTech katman yüksekliği ↔ sıcaklık; birbiriyle çelişen kanallar şüphelidir.
- **Dağılım dışı (OOD) tespiti** ve veri bütünlüğü (imzalı/şifreli akış, yetkisiz kaynak reddi).

Şüpheli girdide: YZ çıktısı güvenilmez işaretlenir ve **kullanılmaz**; YZ'nin parametre önerisi/adaptasyonu kilitlenir; sistem **deterministik SPC moduna (fallback)** düşer, operatöre alarm verir; kritik parçada katman sonunda **güvenli duraklatma** yapılır; olay kaydedilir ve gerekirse Lab 6 olay akışı başlar. Şüpheli girdiyle "devam" hiçbir zaman varsayılan değildir (fail-safe).

3 Confidence düştü: Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Tek eşik değil, **kademeli (tiered) eşik** kullanılır. Sayılar örnektir; gerçek değerler validasyon verisi ve kalibrasyon eğrisinden (confidence ≈ gerçek doğruluk) belirlenir [V]:

Güven bandı	Davranış	Kavram
Yüksek (örn. ≥ 0,90)	Otomatik kabul; ama rastgele örnekleme ve SPC limitleri sürer	monitoring + bağımsız kontrol
Orta (örn. 0,70–0,90)	**İnsana sor:** görüntü/ölçüm operatör ve kalite mühendisine sunulur; karar kaydedilir; bu sırada deposition düşük riskli modda sürer	human override

Güven bandı	Davranış	Kavram
Düşük (örn. < 0,70) veya güven ani düşüş	**Fallback:** YZ devre dışı, deterministik SPC modu; kritik parçada güvenli duraklatma; mühendis incelemesi	fallback + fail-safe

Eşik nasıl belirlenir: parçanın kritikliği (daha kritik → daha yüksek eşik), yanlış negatifin maliyeti, model sapması (drift) izlemesi. Güven düşüşü sürekliyse model yeniden validasyona alınır.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığımız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	YZ "OK" yalnız öneridir; bağımsız SPC limitleri + kritik parçada insan onayı + NDT doğrulaması geçmeden kalite kapısı açılmaz. **(human-in-the-loop · monitoring · defense in depth)**
Girdi manipüle edildi	Sensör sağlığı ve çapraz doğrulamayla tespit; YZ çıktısı kullanılmaz, adaptasyon kilitlenir, deterministik SPC moduna düşülür, kritik parçada güvenli duraklatma, olay kaydı. **(fail-safe · fallback · monitoring)**
Confidence düştü	Kademeli eşik: yüksek → kabul + örnekleme; orta → insana sor; düşük → fallback/duraklat. **(confidence threshold · human override · fallback)**

YZ yetki sınırı — emniyet köprüsü (Lab 1-4 ile bağlantı)

YZ yapabilir	YZ asla yapamaz (R-01…R-08 ve SF-1…SF-6 ile uyumlu)
Uyarı üretmek; duraklatma **talep etmek** (daha güvenli yöne); proses parametresi **önermek**; kalite kaydı yazmak	Emniyet yapılandırmasını/eşiklerini değiştirmek; kapı kilidini, O_2 interlock'u veya ark-enable'ı atlamak/susturmak; güvenlik durdurmasından sonra yeniden başlatmak; alarm limitlerini gevşetmek; uzaktan hareket/ark başlatmak

Siber ve yaşam döngüsü notları: model ve ağırlıkları SBOM'a (AI-BOM) dahil edilir; model güncellemeleri imzalı ve test edilmiş yayın sürecinden geçer (Lab 5 yama mantığı: önce test, sonra emniyet etki analizi); eğitim/test verisinin bütünlüğü korunur; model sürümü her build kaydına işlenir (izlenebilirlik). Çerçeve: ISO/IEC TR 5469 (fonksiyonel emniyet ve YZ), IEC 62443; AB Yapay Zekâ Tüzüğü (EU) 2024/1689 makinelerde emniyet bileşeni olarak kullanılan YZ'yi yüksek riskli sayar ve Makine Yönetmeliği (EU) 2023/1230 ile birlikte okunur **[K]** — takvim ve kapsam resmî metinle doğrulanmalıdır.

▤ Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.